多目標強化學習智慧交通號誌控制系統(PRD)

1. 專案背景與戰略價值分析

1.1 策略背景論述

隨著全球都會區規模持續擴張，交通需求呈現高度非線性與隨機波動的特徵。傳統「固定時制 (Fixed-Time)」與簡易感應式控制已難以負荷現代都市的交通動態，導致路口壅塞成為城市效率的沉沒成本。本計畫旨在透過「數據驅動號誌編排 (Data-driven Signal Orchestration)」轉型，導入進階強化學習技術，將號誌控制由被動反應提升至主動預測模型。這不僅是軟體升級，更是提升城市運作韌性、優化智慧城市移動管理的核心戰略。

1.2 市場趨勢與實績分析

根據全球市場觀測，智慧交通號誌已進入技術與實務結合的爆發成長期。下表彙整當前領先方案與本地實踐之績效：

計畫 / 技術來源	核心技術應用	行車時間 / 延遲改善	社會效益與減碳成效	來源與備註
Google Project Green Light	AI 強化學習 / Google Maps 大數據	減少 30% 停車次數	降低 10% 路口碳排放	[1] 全球多城市實測
NoTraffic & UBC (2025)	V2X / AI 自適應控制 / 邊緣運算	延遲降低達 40-46%	每年減碳 74 噸 / 改善行人安全	[2] 北美智慧路口試驗
臺北市智慧號誌研究	AI 影像辨識 / 即時時制控制	改善 7-15% 行車時間	預估能源減碳效益達 6,000 萬台幣	[3] 2023-2025 擴大建置
高雄市智慧號誌計畫	AI 適應性控制 / 非固定週期	減少 10-20% 旅行時間	停等延滯減少約 10%	[4] 港口聯外與弱勢路段

戰略價值深度分析： 根據 2025-2035 市場預測，全球智慧交通訊號市場正處於高速擴張階段。其中「全球智慧交通號誌」市場在 2025 年預計達 17 億美元，至 2032 年將擴增至 32.1 億美元，年複合成長率 (CAGR) 為 **9.48%** 。而廣義的「智慧訊號市場」規模更預計在 2035 年達到 392 億美元。本計畫透過多目標獎勵機制，精準對接未來十年的市場成長期，並透過 A2C 架構確保技術具備領先 SOTA (State-of-the-Art) 模型的競爭優勢。

1.3 結論過渡

市場數據展現了 AI 應用的經濟潛力，但要實現真正的智慧化運籌，必須解決現有技術在處理複雜交通需求時的盲點，這便引出了本計畫針對技術瓶頸的深度定義。

2. 現有技術瓶頸與問題定義

2.1 挑戰情境建模

在現實路網中，單純追求「效率最大化」的優化邏輯（如僅最小化總體排隊長度）會引發嚴重的社會公平性偏差。當 AI 代理程式為了數據表現而過度傾斜於主幹道流量時，支道車流將面臨長期無法通行的窘境，這種負面體驗將直接降低社會對智慧交通系統的接受度與信賴感。

2.2 核心問題解構

現有的深度強化學習 (DRL) 模型在交通控制場景面臨三大技術痛點：

- 交通分配不公平 **(Starvation)**：如傳統 Max-Pressure (MP) 或 IntelliLight (DQN) 在極端負荷下，易產生「支道飢餓」現象，特定相位長期處於紅燈狀態。
- 號誌切換不穩定性：缺乏對相位切換行為的物理約束，模型可能為了極微小的數值增益而進行不必要的頻繁切換（Signal Flickering）。
- 環境泛化能力受限：多數研究基於過於理想的模擬場景，忽視了真實環境的隨機性 (Stochasticity)，導致從數位孿生過渡到實地部署時表現衰退。

2.3 影響評估

頻繁切換與不可預測的長延遲會嚴重破壞駕駛者的預測性 (Predictability)。若 AI 決策過於跳躍，不僅會增加事故風險，亦會因增加車輛啟動延遲與黃燈時間損失，而抵銷了原有的流量優化成效。

2.4 結論過渡

解決上述痛點的關鍵在於獎勵函數的重構。我們必須將「單一效率最佳化」思維進化為「多目標權衡」架構，以達成穩定且公平的控制。

3. 多目標強化學習系統架構

3.1 技術藍圖概論

本系統建構於「數位孿生 (Digital Twin)」技術之上，採用 **A2C RTQL (Advantage Actor-Critic with Real-Time Queue Lengths)** 作為決策引擎。相較於傳統 IntelliLight (DQN) 或 Fixed-Time 模型，本架構不僅能動態感知交通壓力，更整合了並行環境學習機制，大幅提升面對隨機車流時的決策穩定性。

3.2 開發框架與環境設計

- 高保真模擬環境：基於 SUMO 與 sumo-rl 框架，結合 LWR (Lighthill-Whitham-Richards) 衝擊波理論 (Shockwave Theory) 與感測器融合數據，精準估算即時排隊長度 (RTQL)。
- 隨機性注入機制：在模擬環境中注入隨機車流分布，迫使 Agent 學習應對動態突發流量，而非僅記憶特定模式。
- 技術整合架構：
- **A2C** 代理程式：利用 Advantage 函數降低策略梯度的變異數，確保在異質路口情境下的訓練穩定性。

- 並行訓練系統 **(Parallel Environments)**：如圖所示，系統在多個並行環境中同步收集狀態（s_t）與獎勵（r_t），以顯著提升學習效率並增強模型對不同相位的泛化能力。

3.3 結論過渡

在確立了強健的架構基礎後，本計畫的核心競爭力在於如何精準設計多目標獎勵函數，將抽象的交通指標轉化為 AI 的行為準則。

4. 核心演算法：多目標獎勵函數設計

4.1 設計哲學論述

身為架構師，我們強調控制策略必須符合「人類可接受性 (Human Acceptability)」。我們將號誌控制定義為一個多維度的權衡問題 (Multi-objective Trade-off)，在追求疏解效率的同時，必須將公平與穩定納入數學約束。

4.2 多維度指標解構

本系統採用的獎勵函數 r_t 公式如下，旨在最小化綜合成本：

$$r_t = -(\alpha Q_t + \beta F_t + \gamma S_t + \delta C_t)$$

- 交通壅塞度（Q_t）：定義為各進入車道的總排隊長度或其變化率，對應基礎通行效率。
- 公平性指標（F_t）：採用各向排隊長度的標準差（$std(Q_1, Q_2, Q_3 \ldots)$）。標準差越小代表分配越均勻，從根本上抑制 Starvation 現象。
- 號誌切換穩定性（S_t）：統計過去 k 個時間步內的切換次數，避免過度頻繁的相位變動。
- 切換成本（C_t）：設定為二元指標函數 (Binary Penalty)。若時間 t 發生相位切換則為 1，否則為 0。此項專門補償因黃燈時間與車輛啟動延遲造成的物理通行損失。

4.3 參數影響分析

透過權重參數（$\alpha, \beta, \gamma, \delta$），系統可靈活適應不同路口特性。例如，在商業區幹道可提升 α 以求流量最大化；在住宅區或複雜路口則提升 β 與 γ 以保障跨向公平性與駕駛舒適度。

4.4 結論過渡

此演算法設計確保了 AI 的每一項決策皆經過多重效益評估，其預期帶來的量化績效將為智慧交通實施提供堅實支持。

5. 預期績效指標與實施效益

5.1 效益評估導引

本提案不僅追求技術數值的領先，更重視其在真實路網環境中產生的經濟與社會價值回報，特別是在提升路網韌性方面的表現。

5.2 量化目標設定

依據研究基準與場域模擬推估，本計畫預計達成以下 KPI：

- 停等延滯優化：平均降低 **10-20%** 的路口等待時間。
- 通行時程改善：主要路廊之平均行車時間改善 **7-20%**。
- 路網公平性：顯著降低各向排隊長度標準差，實現無差別交通服務。

- 系統穩定度：相位切換頻率與傳統自適應系統相比降低，提升駕駛可預測性。

5.3 社會與環境價值

- 節能減碳：透過優化怠速時間，大幅降低 CO_2 排放。參考臺北市數據，預估單一路網區域年度節能減碳效益可達數千萬台幣。
- 基礎設施轉型：本系統具備向 C-V2X 環境過渡的潛力，未來可無縫整合邊緣運算節點，實現廣域路網協同控制 (CTDE)。

5.4 結論過渡

雖然技術願景宏大，但作為實施 PRD，我們必須正視從實驗室過渡到道路實體時的各項潛在風險。

6. 實施挑戰與風險控管

6.1 風險環境分析

智慧交通系統的落地受限於硬體相容性、法規環境以及國際經貿政策。必須針對邊緣端部署的穩定性進行嚴格把關。

6.2 關鍵挑戰清單

- 技術與硬體挑戰：
- 現有資產改裝需求：舊型號誌控制機 (Controller) 的運算資源可能難以負荷 DRL 模型的即時推理，需考慮增設邊緣運算模組。
- 感知精度限制：在惡劣天氣（如強降雨、低照度）下，影像辨識的 RTQL 觀測可能失效，需建立基於 LWR 理論的容錯補償演算法。
- 環境與政策風險：
- 供應鏈與關稅衝擊 **(Tariff Impacts)**：國際貿易政策與關稅調整可能顯著增加高精度感測器與 AI 處理器的採購成本，需建立多元供應來源。
- 跨學科協作成本：AI 技術專家 (IT) 與傳統交通工程師在號誌相位邏輯上的認知差異，需透過建立標準化溝通介面來消弭。

6.3 總結與展望

本多目標 DRL 技術提案不僅優化了交通效率，更透過公平性與穩定性的數學建模，修補了既有 AI 模型的實務缺陷。我們將以此為基礎，為未來具備 V2I 協同能力的智慧城市路網，奠定最為穩固且具備高接受度的控制典範。

7. 參考資料

https://www.gii.tw/report/ires1950117-smart-traffic-light-market-by-components.html
https://www.researchnester.com/tw/reports/smart-signaling-market/3262
https://www.airitilibrary.com/Article/Detail/15621189-N202501210011-00005
https://www.airitilibrary.com/Article/Detail/10272275-N202412030004-00003
https://www.iot.gov.tw/zh_tw/archive/pub/reports/-48081145
https://geneonline.news/%E6%99%BA%E8%83%BD%E4%BA%A4%E9%80%9A%E6%A8%99%E8%AA%8C%E8%AD%98%E5%88%A5%E6%8A%80%E8%A1%93%E7%99%BC%E5%B1%95%E7%8F%BE%E7%8B%80%E8%88%87%E6%9C%AA%E4%BE%86%E8%B6%A8%E5%8B%A2%E5%88%86%E6%9E%90/

https://scitechvista.nat.gov.tw/Article/c000008/detail?ID=c9fe4c48-59e9-40b7-a957-f0f856e22862
Varaiya, P. (2013). Max pressure control of a network of signalized intersections. Transportation Research Part C: Emerging Technologies, 36, 177–195.
Wei, H., et al. (2015). Variants of max pressure control for signalized intersections. In Proceedings of the Transportation Research Board Annual Meeting. UC Berkeley Connected Corridors.
Wei, H., Zheng, G., Yao, H., & Li, Z. (2018). IntelliLight: A reinforcement learning approach for intelligent traffic light control. In Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (pp. 2496–2505). ACM.
Sun, Q. W., Han, S. Y., Zhou, J., Chen, Y. H., & Yao, K. (2022, October). Deep reinforcement-learning-based adaptive traffic signal control with real-time queue lengths. In 2022 IEEE International Conference on Systems, Man, and Cybernetics (SMC) (pp. 1760-1765). IEEE.